

REPUBLIQUE DEMOCRATIQUE ET POPULAIRE D'ALGERIE
Ministère de l'Enseignement Supérieur et de la Recherche Scientifique
Université des Sciences et de la Technologie Houari Boumediene



Faculté d'Informatique
Département de Système Informatique
Spécialité : Big Data

Projet De Business Intelligence

Sujet

CREATION D'UNE DATA WHEREHOUSE

Présenté par :
Smail Sofia

Encadré par :
Mme Mekahlia Fatma Zohra

ANNEE ACADEMIQUE : 2025/2026

Table des matières

1	Création de DataWherehouse	4
1.1	Power BI :	4
1.1.1	Installation de PowerBI	4
1.1.2	Exportation des données :	5
1.1.3	Préparation et nettoyage des données	7
1.1.4	Création des dimensions :	23
1.2	Talend Open Studio :	35
1.2.1	Création des demensions	35
1.3	Comparaison entre Power BI et Talend	38
1.3.1	Rôle de Power BI	38
1.3.2	Rôle de Talend Open Studio	38
1.3.3	Comparaison synthétique	38
2	Visualisation	39
2.1	Power BI	40
2.1.1	Les commandes livrées et non livrées par années :	40
2.1.2	Les commandes livrées et non livrées par Client :	41
2.1.3	Le nombre de commandes livrées et non livrées par employé :	41
2.1.4	Les commandes livrées et non livrées par Country :	43
2.1.5	Le dashboard final	44
2.2	2.Tableau	44
2.2.1	Les commandes livrées et non livrées par années :	44
2.2.2	Les commandes livrées et non livrées par Client :	45
2.2.3	Le nombre de commandes livrées et non livrées par employé :	45
2.2.4	Les commandes livrées et non livrées par Country :	46
2.2.5	Le dashboard final	
2.3	3.Python	
2.3.1	Les commandes livrées et non livrées par années :	55
2.3.2	Les commandes livrées et non livrées par Client :	56
2.3.3	Le nombre de commandes livrées et non livrées par employé :	57
2.3.4	Les commandes livrées et non livrées par Country :	58
	Le dashboard final	58

INTRODUCTION

Dans le contexte actuel de la transformation numérique, les entreprises accumulent des volumes considérables de données qu'elles doivent exploiter pour en extraire de la valeur et éclairer leurs décisions stratégiques. Le processus ETL (Extract, Transform, Load) constitue la pierre angulaire de toute solution de Business Intelligence, permettant de transformer des données opérationnelles brutes en informations exploitables.

Le présent rapport documente la conception et la réalisation d'un processus ETL complet appliqué à la base de données Northwind, en utilisant Microsoft Power BI. La base Northwind, créée par Microsoft comme base de démonstration, représente les opérations d'une entreprise fictive de commerce international spécialisée dans la distribution de produits alimentaires. Elle contient des informations sur les ventes, les clients, les produits, les employés et les fournisseurs.

L'objectif principal de ce projet est de transformer ces données transactionnelles (OLTP) en un modèle dimensionnel optimisé pour l'analyse décisionnelle (OLAP), suivant la méthodologie de Ralph Kimball. Ce processus s'articule autour de trois phases fondamentales :

- Extract : Extraction des données depuis différentes sources (SQL Server et fichiers Excel) et leur intégration dans Power Query.
- Transform : Nettoyage, standardisation et enrichissement des données pour garantir leur qualité et leur cohérence.
- Load : Construction d'un modèle dimensionnel en étoile (star schema) composé de tables de dimensions et d'une table de faits, optimisé pour les analyses multidimensionnelles.

Pour mener à bien ce projet, plusieurs outils complémentaires ont été mobilisés :

- Power BI: pour l'extraction, la transformation, la modélisation et la visualisation des données
- Talend Open Studio : pour illustrer les processus ETL alternatifs et la création des dimensions .
- Tableau: pour créer des visualisations avancées et des tableaux de bord interactifs
- Python et Streamlit : pour développer une application web interactive de visualisation

Ce rapport présente de manière détaillée chaque étape du processus ETL, depuis l'installation de Power BI jusqu'à la création du modèle dimensionnel final et sa visualisation, en passant par toutes les transformations appliquées. Il vise à démontrer la maîtrise des techniques de préparation et de modélisation des données dans le cadre du module Technologies Business Intelligence du Master Big Data Analytics.

INTRODUCTION À POWER BI

1.1.Présentation de l'outil Power BI

Power Business Intelligence (Power BI) est défini comme étant une suite d'outils d'analyse commerciale permettant d'analyser des données et de partager des informations. Le site officiel de Microsoft le présente comme une plateforme de Business Intelligence permettant de transformer des données brutes en visualisations interactives et en tableaux de bord exploitables.

1.2.Architecture de Power BI

Power BI s'articule autour de trois composants principaux :

1. Power BI Desktop : Application Windows gratuite pour créer des rapports et modèles de données. C'est l'outil de développement principal utilisé dans ce projet.
2. Power BI Service : Plateforme cloud pour partager et collaborer sur les rapports créés. Permet la publication et le partage sécurisé des tableaux de bord.
3. Power BI Mobile : Applications mobiles (iOS, Android, Windows) pour consulter les rapports sur smartphone et tablette.

1.3.Processus de travail dans Power BI

Le processus de travail dans Power BI suit généralement ces étapes :

1. Récupération des données : Via le bouton "Obtenir des données" qui propose plus de 150 connecteurs (Excel, bases SQL, services cloud, API web, etc.)
2. Transformation avec Power Query : Permet de nettoyer, filtrer et transformer les tables sans altérer les sources originales. Power Query utilise le langage M pour définir les transformations.
3. Modélisation : Établissement des relations entre les tables et création d'un modèle de données cohérent (schéma en étoile ou flocon).
4. Calculs avec DAX : Création de mesures et colonnes calculées avec le langage DAX (Data Analysis Expressions).
5. Visualisation : Construction de rapports interactifs en glissant-déposant les champs sur la vue Rapport, avec une bibliothèque riche de visuels personnalisables.

INSTALLATION ET CONFIGURATION

2.1. Prérequis système

Avant d'installer Power BI Desktop, il est essentiel de vérifier que le système répond aux exigences minimales définies par Microsoft :

Configuration matérielle minimale

- Système d'exploitation : Windows 10 (version 1809 ou ultérieure) ou Windows 11
- Processeur : Processeur x64 à 1 GHz ou supérieur
- Mémoire RAM : Minimum 2 Go (8 Go recommandés pour des performances optimales)
- Espace disque : Au moins 2,5 Go d'espace disponible
- Résolution d'écran : 1440 × 900 ou supérieure (1920 × 1080 recommandé)
- Connectivité : Connexion Internet pour le téléchargement, les mises à jour et l'utilisation de certaines fonctionnalités

2.2. Logiciels requis

- Framework .NET : .NET Framework 4.7.2 ou version ultérieure (généralement déjà installé sur Windows 10/11)
- Navigateur web moderne : Pour accéder au Power BI Service (Edge, Chrome, Firefox)

2.3. Recommandations pour de meilleures performances

Pour travailler confortablement avec Power BI, particulièrement sur des modèles de données volumineux, il est recommandé de disposer de :

- RAM : 16 Go ou plus
- Processeur : Intel Core i5 ou AMD Ryzen 5 (ou supérieur)
- Disque SSD : Pour des temps de chargement plus rapides
- Écran : Résolution Full HD (1920 × 1080) ou supérieure pour profiter pleinement de l'interface

2.4. Téléchargement et installation de Power BI Desktop

Étape 1 : Accès au site officiel


1. Ouvrir un navigateur web
2. Accéder au site officiel de Microsoft Power BI : <https://powerbi.microsoft.com/desktop>
3. La page d'accueil présente Power BI Desktop avec un bouton de téléchargement principal



Étape 2 : Options de téléchargement

Cliquer sur le bouton "**Options de téléchargement avancées**" pour accéder aux options suivantes :


- Téléchargement direct : fichier .exe d'environ 800 Mo
- Microsoft Store : installation via le Windows Store (mise à jour automatique)
- Choix de la langue : Sélectionner la langue souhaitée (Français, Anglais, etc.)



Développer tout | [Réduire tout](#)


Pour ce projet, nous utilisons le téléchargement direct :

1. Sélectionner la langue : ****Français****
2. Cliquer sur ****"Télécharger"****
3. Enregistrer le fichier ****PBIDesktopSetup_x64.exe**** dans un emplacement connu (par exemple : Téléchargements)



Étape 3 : Exécution de l'installation

1. Localiser le fichier téléchargé (PBIDesktopSetup_x64.exe)
2. Clic droit sur le fichier
3. Si Windows affiche un avertissement de sécurité, cliquer sur ****"Oui"**** pour autoriser l'installation



Étape 4 : Assistant d'installation

L'assistant d'installation Power BI s'ouvre. Suivre les étapes suivantes :


1. Écran de bienvenue : Cliquer sur **"Suivant"**
2. Contrat de licence :
 - Lire les termes du contrat de licence utilisateur final
 - Cocher la case **"J'accepte les termes du contrat de licence"**
 - Cliquer sur **"Suivant"**
3. Emplacement d'installation
 - Répertoire par défaut : `C:\Program Files\Microsoft Power BI Desktop`
 - Modifier l'emplacement si nécessaire (non recommandé)
 - Cliquer sur **"Suivant"**
4. Options d'installation :
 - Cocher **"Créer un raccourci sur le Bureau"** (recommandé)
 - Cocher **"Ajouter au menu Démarrer"**
 - Cliquer sur **"Installer"**
5. Progression de l'installation :
 - L'installation prend environ 3-5 minutes
 - Une barre de progression affiche l'avancement
6. Fin de l'installation :
 - Message "Installation terminée avec succès"
 - Option **"Lancer Power BI Desktop"** (laisser cochée)
 - Cliquer sur **"Terminer"**




Étape 5 : Premier lancement

Lors du premier lancement de Power BI Desktop :

1. **Écran de démarrage** s'affiche avec plusieurs options :
 - Créer un rapport vierge
 - Ouvrir un exemple de rapport
 - Accéder à des tutoriels



2. Pour ce projet, sélectionner **"Blank report"** (Rapport vierge)




Étape 6 : Configuration initiale

Avant de commencer le projet :

1. Enregistrer le fichier :

- Cliquer sur **Fichier** > **Enregistrer sous**
- Nommer le fichier : `Northwind\_DataWarehouse.pbix`
- Cliquer sur **Enregistrer**



2. Configurer les options :

- Aller dans **Fichier** > **Options et paramètres** > **Options**
- Ajuster les paramètres selon les préférences (langue, thème, etc.)

3. Vérifier les mises à jour :

- Power BI vérifie automatiquement les mises à jour
- Il est recommandé d'utiliser toujours la dernière version

L'installation est maintenant terminée et Power BI Desktop est prêt à être utilisé pour le projet de création du Data Warehouse.

Chapitre 1

Création de DataWarehouse


Dans ce chapitre, je présente les étapes nécessaires pour création du Data Warehouse. Et j'ai utilisé deux outils :

- **Power BI.**
- **Talend Open Studio.**

1.1 Power BI :



Dans Power BI, j'ai commencé par réaliser l'ETL via Power Query afin de préparer et nettoyer les données, puis j'ai construit le modèle et les visualisations.

1.1.1 Exportation des données :





La première étape consiste à connecter Power BI aux différentes sources :
Source SQL Server : Pour récupérer les tables provenant de la base Northwind :

1. Cliquer sur **"Obtenir les données"** dans le ruban Accueil
2. Sélectionner l'option **"SQL Server"**
3. Une fenêtre apparaît demandant :
 - **Serveur** : Nom du serveur SQL (exemple : HOUDASQLEXPRESS)
 - **Base de données** : Northwind
 - **Mode de connectivité** : Import (recommandé pour ce projet)





Une fois ces informations renseignées, Power BI affiche la liste des tables disponibles et je peux choisir sélectionner les tables nécessaires.






- **Source Excel** : les fichiers Excel, j'utilise également l'option **Obtenir les données**, puis je choisis la source **Excel**. Une fenêtre s'ouvre et me permet de sélectionner le fichier contenant les tables (Customers, Orders, Employees, etc.).




Une fois le fichier chargé, Power BI affiche les feuilles disponibles et je peux choisir celles que je veux importer.




1.1.2 Préparation et nettoyage des données

Après l'importation, les tables sont ouvertes dans **Power Query** pour appliquer les transformations nécessaires. Dans Accueil je cliqué sur **Transformer Les données**




Une fenêtre s'ouvre :




1. Table Customer

1.1. Source SQL Server

J'ai ajouté une colonne Source_Prod pour indiquer la source des données.



Ensuite, j'ai sélectionné uniquement les colonnes nécessaires pour le traitement.



Le résultat sera :

Requêtes [9] X ✓ f - Table.SelectColumns("#Colonnes supprimées!","CustomerID", "CompanyName", "City", "Country", "Source_Prod") Paramètres d'une requête X

CustomerID	CompanyName	City	Country	Source_Prod
1 ALFKI	Alfreds Futterkiste	Berlin	Germany	Sql Server
2 ANATR	Ana Trujillo Emparedados y helados	México D.F.	Mexico	Sql Server
3 ANTON	Antonio Moreno Taquería	México D.F.	Mexico	Sql Server
4 AROUT	Around the Horn	London	UK	Sql Server
5 BERGS	Berglunds snabbköp	Luleå	Sweden	Sql Server
6 BLAUS	Blauer See Delikatessen	Mannheim	Germany	Sql Server
7 BLONP	Blondiesdidi père et fils	Strasbourg	France	Sql Server
8 BOUD	Bólido Comidas preparadas	Madrid	Spain	Sql Server
9 BONAP	Bon app'	Marseille	France	Sql Server
10 BOTTM	Bottom-Dollar Markets	Tsawassen	Canada	Sql Server
11 BSBEV	B's Beverages	London	UK	Sql Server
12 CACTU	Cactus Comidas para llevar	Buenos Aires	Argentina	Sql Server
13 CENTC	Centro comercial Moctezuma	México D.F.	Mexico	Sql Server
14 CHOPS	Chop-suey Chinese	Bern	Switzerland	Sql Server
15 CONMI	Comércio Mineiro	Sao Paulo	Brazil	Sql Server
16 CONSH	Consolidated Holdings	London	UK	Sql Server
17 DRACD	Drachenblut Delikatessen	Aachen	Germany	Sql Server
18 DUMON	Du monde entier	Nantes	France	Sql Server
19 EASTC	Eastern Connection	London	UK	Sql Server
20 ERNSH	Ernst Handel	Graz	Austria	Sql Server
21 FAMIA	Familia Arquibaldo	Sao Paulo	Brazil	Sql Server
22 FISSA	FISSA Fabrica Inter. Salchichas S.A.	Madrid	Spain	Sql Server
23 FOUG	Folies gourmandes	Lille	France	Sql Server
24 FOIXO	Folk och få Hb	Bräcke	Sweden	Sql Server
25 FRANK	Frankenversand	München	Germany	Sql Server
26 FRANR	France restauration	Nantes	France	Sql Server



5 COLONNES, 91 LIGNES Profilage de la colonne en fonction des 1000 premières lignes APERÇU TÉLÉCHARGÉ À 11:40

PROPRIÉTÉS
Nom: Customers
Toutes les propriétés


ÉTAPES APPLIQUÉES
Source ✖
Navigation ✖
Personnalisée ajoutée ✖
Colonnes supprimées ✖
Personnalisée ajoutée1 ✖
Colonnes supprimées1 ✖
Autres colonnes supprimées ✖

1.2. Source Excel


D'abord j'ai sélectionné uniquement les colonnes nécessaires.




Deuxième, j'ai ajouté une colonne Source_Prod pour indiquer la source des données.




Ensuite j'ai renommé les colonnes pour qu'elles correspondent aux noms de la source
1. j'ai clic sur le droit de chaque colone et choisi **Renommer**.



Enfin, modifié le type de la colonne CustomerID de source excel en texte



Le résultat sera :



2. Table Employee

1.1. Source SQL Server

J'ai sélectionné uniquement les colonnes nécessaires pour le traitement.

The image shows two parts of the Power Query interface. On the left is the 'Choisir les colonnes' (Choose columns) dialog box. It has a title bar with a close button. Below the title is a search bar and a list of columns from the 'Employees' table. The columns 'EmployeeID', 'LastName', and 'FirstName' are checked, while others like 'Title', 'BirthDate', etc., are unchecked. At the bottom are 'OK' and 'Annuler' buttons. On the right is the 'Requêtes' (Queries) pane. It shows a list of queries on the left: Customers, Employees (selected), EmployeeTerritories, Orders, Region, Territories, Customers (2), Employees (2), and Orders (2). The main area shows the formula bar with the query: `= Table.SelectColumns(dbo_Employees, {"EmployeeID", "LastName", "FirstName"})`. Below the formula bar is a table with 9 rows and 3 columns: EmployeeID, LastName, and FirstName. The data is as follows:

EmployeeID	LastName	FirstName
1	Davolio	Nancy
2	Fuller	Andrew
3	Leverling	Janet
4	Peacock	Margaret
5	Buchanan	Steven
6	Suyama	Michael
7	King	Robert
8	Callahan	Laura
9	Dodsworth	Anne

Ensuite, J'ai ajouté une colonne Source_Prod pour indiquer la source des données.



The image shows two parts of the Power Query interface. On the left is a context menu with various options. The option 'Ajouter une colonne personnalisée...' (Add custom column) is highlighted. On the right is the 'Colonne personnalisée' (Custom column) dialog box. It has a title bar with a close button. Below the title is a text box for 'Nouveau nom de colonne' (New column name) with the value 'Source_Prod'. Below that is a text box for 'Formule de colonne personnalisée' (Custom column formula) with the value '= "Sql Server"'. To the right of the formula box is a list of 'Colonnes disponibles' (Available columns): EmployeeID, LastName, and FirstName. At the bottom right is an '<< Insérer' button. At the bottom left is a green checkmark and the text 'Aucune erreur de syntaxe n'a été détectée.' (No syntax error was detected). At the bottom right are 'OK' and 'Annuler' buttons.

Le résultat sera :


EmployeeID	LastName	FirstName	Source_Prod
1	Davolio	Nancy	Sql Server
2	Fuller	Andrew	Sql Server
3	Leverling	Janet	Sql Server
4	Peacock	Margaret	Sql Server
5	Buchanan	Steven	Sql Server
6	Suyama	Michael	Sql Server
7	King	Robert	Sql Server
8	Callahan	Laura	Sql Server
9	Dodsworth	Anne	Sql Server

1.2. Source Excel


D'abord j'ai sélectionné uniquement les colonnes nécessaires.




Deuxième, j'ai ajouté une colonne Source_Prod pour indiquer la source des données.



Ensuite j'ai renommé les colonnes pour qu'elles correspondent aux noms de la source 1. j'ai cliqué sur le droit de chaque colonne et choisi **Renommer**.




Le résultat sera :



	EmployeeID	LastName	FirstName	Source_Prod
1	1	Freehater	Nancy	Excel
2	2	Gendini	Andrew	Excel
3	3	Kotas	Jan	Excel
4	4	Sergienko	Mariya	Excel
5	5	Thorpe	Steven	Excel
6	6	Mejper	Michael	Excel
7	7	Zare	Robert	Excel
8	8	Ghassani	Laura	Excel
9	9	Helming-Larsen	Anne	Excel

3.Table EmployeeTerritories



	EmployeeID	TerritoryID	Employees	Territories
1	1	06897	Value	Value
2	1	19713	Value	Value
3	2	01581	Value	Value
4	2	01730	Value	Value
5	2	01833	Value	Value
6	2	02116	Value	Value
7	2	02139	Value	Value
8	2	02194	Value	Value
9	2	40222	Value	Value
10	3	30346	Value	Value
11	3	31406	Value	Value
12	3	32859	Value	Value
13	3	33607	Value	Value
14	4	20852	Value	Value
15	4	27403	Value	Value
16	4	27511	Value	Value
17	5	02903	Value	Value
18	5	07960	Value	Value
19	5	08837	Value	Value
20	5	10019	Value	Value
21	5	10038	Value	Value
22	5	11747	Value	Value
23	5	14450	Value	Value
24	6	85014	Value	Value
25	6	85151	Value	Value
26	6	98004	Value	Value

4. Table Territories

Requêtes [9]

Customers

Employees

EmployeeTerritories

Orders

Region

Territories

Customers (2)

Employees (2)

Orders (2)

Formulaire de requête

Source: [Schema="dbo",Item="Territories"] [Data]

	TerritoryID	TerritoryDescription	RegionID	EmployeeTerritories	Region
1	01581	Westboro	1	Table	Value
2	01730	Bedford	1	Table	Value
3	01833	Georgetown	1	Table	Value
4	02116	Boston	1	Table	Value
5	02139	Cambridge	1	Table	Value
6	02184	Braintree	1	Table	Value
7	02903	Providence	1	Table	Value
8	03049	Hollis	3	Table	Value
9	03801	Portsmouth	3	Table	Value
10	06897	Wilton	1	Table	Value
11	07960	Morristown	1	Table	Value
12	08837	Edison	1	Table	Value
13	10019	New York	1	Table	Value
14	10038	New York	1	Table	Value
15	11747	Melville	1	Table	Value
16	14450	Fairport	1	Table	Value
17	13428	Philadelphia	3	Table	Value
18	13713	Neward	1	Table	Value
19	20852	Rockville	1	Table	Value
20	27403	Greensboro	1	Table	Value
21	27511	Cary	1	Table	Value
22	29202	Columbia	4	Table	Value
23	30346	Atlanta	4	Table	Value
24	31406	Savannah	4	Table	Value
25	32859	Orlando	4	Table	Value
26	32932	Tampa	4	Table	Value

Paramètres d'une requête

PROPRIÉTÉS

Nom

Territories

Toutes les propriétés

ÉTAPES APPLIQUÉES

Source

X Navigation

4. Table Region

Requêtes [9]

Customers

Employees

EmployeeTerritories

Orders

Region

Territories

Customers (2)

Employees (2)

Orders (2)

Formulaire de requête

Source: [Schema="dbo",Item="Region"] [Data]

	RegionID	RegionDescription	Territories
1	1	Eastern	Table
2	2	Western	Table
3	3	Northern	Table
4	4	Southern	Table

Paramètres d'une requête

PROPRIÉTÉS

Nom

Region

Toutes les propriétés

ÉTAPES APPLIQUÉES



Source

X Navigation



5. Table Orders

1.1. Source SQL Server

J'ai sélectionné uniquement les colonnes nécessaires pour le traitement.



Deuxième, j'ai ajouté une colonne ShippedDateAM pour faire fusion avec le table temps.





Le résultat sera :

Requêtes [9] ✕ ✓ fx = Table.ReorderColumns("#Personnalisée ajoutée1",{ "OrderID", "CustomerID", "EmployeeID", "OrderDate", "ShippedDate",


	OrderID	CustomerID	EmployeeID	OrderDate	ShippedDate	ShippedDate-AnneeMois	Shipper
3	10250	HANAR	4	08/07/1996 00:00:00	12/07/1996 00:00:00	1996-07	Value
4	10251	VICTE	3	08/07/1996 00:00:00	15/07/1996 00:00:00	1996-07	Value
5	10252	SUPRD	4	09/07/1996 00:00:00	11/07/1996 00:00:00	1996-07	Value
6	10253	HANAR	3	10/07/1996 00:00:00	16/07/1996 00:00:00	1996-07	Value
7	10254	CHOPS	5	11/07/1996 00:00:00	23/07/1996 00:00:00	1996-07	Value
8	10255	RICSU	9	12/07/1996 00:00:00	15/07/1996 00:00:00	1996-07	Value
9	10256	WELLI	3	15/07/1996 00:00:00	17/07/1996 00:00:00	1996-07	Value
10	10257	HILAA	4	16/07/1996 00:00:00	22/07/1996 00:00:00	1996-07	Value
11	10258	ERNSH	1	17/07/1996 00:00:00	23/07/1996 00:00:00	1996-07	Value
12	10259	CENTC	4	18/07/1996 00:00:00	25/07/1996 00:00:00	1996-07	Value
13	10260	OTTIK	4	19/07/1996 00:00:00	29/07/1996 00:00:00	1996-07	Value
14	10261	QUEDE	4	19/07/1996 00:00:00	30/07/1996 00:00:00	1996-07	Value
15	10262	RATTC	8	22/07/1996 00:00:00	25/07/1996 00:00:00	1996-07	Value
16	10263	ERNSH	9	23/07/1996 00:00:00	31/07/1996 00:00:00	1996-07	Value
17	10264	FOLKO	6	24/07/1996 00:00:00	23/08/1996 00:00:00	1996-08	Value
18	10265	BLONP	2	25/07/1996 00:00:00	12/08/1996 00:00:00	1996-08	Value
19	10266	WARTH	3	26/07/1996 00:00:00	31/07/1996 00:00:00	1996-07	Value
20	10267	FRANK	4	29/07/1996 00:00:00	06/08/1996 00:00:00	1996-08	Value
21	10268	GROSR	8	30/07/1996 00:00:00	02/08/1996 00:00:00	1996-08	Value
22	10269	WHITC	5	31/07/1996 00:00:00	09/08/1996 00:00:00	1996-08	Value
23	10270	WARTH	1	01/08/1996 00:00:00	02/08/1996 00:00:00	1996-08	Value
24	10271	SPLUR	6	01/08/1996 00:00:00	30/08/1996 00:00:00	1996-08	Value
25	10272	RATTC	6	02/08/1996 00:00:00	06/08/1996 00:00:00	1996-08	Value
26	10273	QUICK	3	05/08/1996 00:00:00	12/08/1996 00:00:00	1996-08	Value
27	10274	VINET	6	06/08/1996 00:00:00	16/08/1996 00:00:00	1996-08	Value
28	10275	MAGAA	1	07/08/1996 00:00:00	09/08/1996 00:00:00	1996-08	Value

1.2. Source Excel


D'abord j'ai sélectionné uniquement les colonnes nécessaires.




Deuxième, j'ai ajouté une colonne ShippedDateAM pour faire fusion avec le table temps.



Ensuite j'ai renommé les colonnes pour qu'elles correspondent aux noms de la source 1. j'ai clic sur le droit de chaque colone et choisi **Renommer**.



Enfin, modifié le type de la colonne CustomerID de source excel en texte



Le résultat sera :

Requêtes [1]

Customers

Employees

EmployeeTerritories

Orders

Region

Territories

Customers (2)

Employees (2)

Orders (2)

Table.AddColumn(#"Colonnes renommées1", "ShipDate_AnnéeMois", each if [ShipDate] = null then "" else Date.ToText(Date.From(

OrderID	EmployeeID	CustomerID	OrderDate	ShipDate	ShipDate_AnnéeMois
1	30	9 17	15/01/2006	22/01/2006	2006-01
2	31	3 4	20/01/2006	22/01/2006	2006-01
3	32	4 12	22/01/2006	22/01/2006	2006-01
4	33	6 8	30/01/2006	31/01/2006	2006-01
5	34	9 4	06/02/2006	07/02/2006	2006-02
6	35	3 19	10/02/2006	12/02/2006	2006-02
7	36	4 3	23/02/2006	25/02/2006	2006-02
8	37	8 6	06/03/2006	09/03/2006	2006-03
9	38	9 18	10/03/2006	11/03/2006	2006-03
10	39	3 8	22/03/2006	24/03/2006	2006-03
11	40	4 10	24/03/2006	24/03/2006	2006-03
12	41	1 7	24/03/2006	null	
13	42	1 10	24/03/2006	07/04/2006	2006-04
14	43	1 11	24/03/2006	null	
15	44	1 1	24/03/2006	null	
16	45	1 28	07/04/2006	07/04/2006	2006-04
17	46	7 9	05/04/2006	05/04/2006	2006-04
18	47	6 6	08/04/2006	08/04/2006	2006-04
19	48	4 8	05/04/2006	05/04/2006	2006-04
20	50	9 25	05/04/2006	05/04/2006	2006-04
21	51	9 26	05/04/2006	05/04/2006	2006-04
22	55	1 19	05/04/2006	05/04/2006	2006-04
23	56	2 6	03/04/2006	03/04/2006	2006-04
24	57	9 17	22/04/2006	22/04/2006	2006-04
25	58	3 4	22/04/2006	22/04/2006	2006-04
26	59	4 12	22/04/2006	22/04/2006	2006-04

Paramètres d'une requête

PROPRIÉTÉS

Nom

Orders (2)

Toutes les propriétés

ÉTAPES APPLIQUÉES

Source

Navigation

En-têtes promus

Type modifié

Colonnes renommées

Autres colonnes supprimées


Type modifié1

Colonnes renommées1

Personnalisée ajoutée

6. Explication des étapes appliquées


L'image ci-dessous représente la zone **Étapes appliquées** dans Power Query. Comme l'image est petite, les transformations sont décrites ci-dessous pour une meilleure lisibilité.



- **Source** : connexion à la base de données ou au fichier d'origine.
- **Navigation** : sélection de la table ou de la feuille dans la source.
- **Personnalisée ajoutée** : ajout d'une colonne calculée (ex. *Source_Prod* ou *ShippedDate-AnneeMois*).
- **Colonnes supprimées** : suppression des colonnes inutiles.
- **Personnalisée ajoutée1** : ajout d'une autre colonne personnalisée si nécessaire.
- **Colonnes supprimées1** : seconde étape de suppression pour affiner le nettoyage.
- **Autres colonnes supprimées** : filtrage final pour ne garder que les colonnes essentielles.

Ces étapes correspondent à la chronologie complète des transformations effectuées sur la table. Elles permettent de suivre, modifier ou corriger le processus de préparation des données à tout moment.

Après la préparation des données, je clique sur Fermer et appliquer, puis je passe à la deuxième page pour vérifier.



Donc on a :

Projet_BI • Dernière enregistrement : Aujourd'hui à 11:16

Fichier Accueil Aide Outils de table

Nom Customers

Structure

Gérer les relations Relations

Nouvelle mesure Calculs

Mesure rapide

Nouvelle colonne

Nouvelle table

Marquer comme table de dates Calendriers



CustomerID	CompanyName	City	Country	Source_Prod
ALFKI	Alfreds Futterkiste	Berlin	Germany	Sql Server
ANATR	Ana Trujillo Emparedados y helados	México D.F.	Mexico	Sql Server
ANTON	Antonio Moreno Taquería	México D.F.	Mexico	Sql Server
AROUT	Around the Horn	London	UK	Sql Server
BERGS	Berglunds snabbköp	Luleå	Sweden	Sql Server
BLAUS	Blauer See Delikatessen	Mannheim	Germany	Sql Server
BLOPP	Blondesdddsl père et fils	Strasbourg	France	Sql Server
BOLID	Bólido Comidas preparadas	Madrid	Spain	Sql Server
BONAP	Bon app'	Marseille	France	Sql Server
BOTTM	Bottom-Dollar Markets	Tsawassen	Canada	Sql Server
BSBEV	B's Beverages	London	UK	Sql Server
CACTU	Cactus Comidas para llevar	Buenos Aires	Argentina	Sql Server
CENTC	Centro comercial Moctezuma	México D.F.	Mexico	Sql Server
CHOPS	Chop-suey Chinese	Bern	Switzerland	Sql Server
COMMI	Comércio Mineiro	Sao Paulo	Brazil	Sql Server
CONSH	Consolidated Holdings	London	UK	Sql Server
DRACD	Drachenblut Delikatessen	Aachen	Germany	Sql Server
DUMON	Du monde entier	Nantes	France	Sql Server
EASTC	Eastern Connection	London	UK	Sql Server
ERNSH	Ernst Handel	Graz	Austria	Sql Server

1.1.3 Création des dimensions :



1. Création de la dimension Customers :

Pour créer une dimension je fais les étapes suivantes :

1. J'ai cliqué sur Entrée des données.



2. puis j'ai ajouté les requêtes nécessaires.





Le résultat sera :



	CustomerID	CompanyName	City	Country	Source_Prod
77	THEBI	The Big Cheese	Portland	USA	Sql Server
78	THECR	The Cracker Box	Butte	USA	Sql Server
79	TOMSP	Toms Spezialitäten	Münster	Germany	Sql Server
80	TORTU	Tortuga Restaurante	México D.F.	Mexico	Sql Server
81	TRADH	Tradição Hipermercados	Sao Paulo	Brazil	Sql Server
82	TRAIH	Trail's Head Gourmet Provisioners	Kirkland	USA	Sql Server
83	VAFFE	Vaffeljernet	Århus	Denmark	Sql Server
84	VICTE	Victualles en stock	Lyon	France	Sql Server
85	VINET	Vins et alcools Chevalier	Reims	France	Sql Server
86	WANDK	Die Wandernde Kuh	Stuttgart	Germany	Sql Server
87	WARTH	Wartian Herkku	Oulu	Finland	Sql Server
88	WELLI	Wellington Importadora	Resende	Brazil	Sql Server
89	WHITC	White Clover Markets	Seattle	USA	Sql Server
90	WILMK	Wilman Kala	Helsinki	Finland	Sql Server
91	WOLZA	Wolski Zajazd	Warszawa	Poland	Sql Server
92	1	Company A	Seattle	USA	Excel
93	2	Company B	Boston	USA	Excel
94	3	Company C	Los Angeles	USA	Excel
95	4	Company D	New York	USA	Excel
96	5	Company E	Minneapolis	USA	Excel
97	6	Company F	Milwaukee	USA	Excel
98	7	Company G	Boise	USA	Excel
99	8	Company H	Portland	USA	Excel
100	9	Company I	Salt Lake City	USA	Excel
101	10	Company J	Chicago	USA	Excel
102	11	Company K	Miami	USA	Excel

2. Création de la dimension Temps

Pour créer la dimension Temps, je me rends dans l'onglet **Accueil**, puis je clique sur **Obtenir les données** et je sélectionne **Requête vide**. Une nouvelle fenêtre Power Query s'ouvre.



Ensuite, je clique sur **Éditeur avancé** et j'insère la requête M permettant de générer automatiquement la table de dates.



Après validation, la table est créée dans Power Query et s'affiche dans l'interface. Enfin, je renomme cette table en **DIM_Temps** afin de l'utiliser comme dimension dans le modèle.



= Table.ReorderColumns("#Index ajouté", {"ID_SEQ", "annee", "mois_annee"})			
	ID_SEQ	annee	mois_annee
1	1	1996	1996-01
2	2	1996	1996-02
3	3	1996	1996-03
4	4	1996	1996-04
5	5	1996	1996-05
6	6	1996	1996-06
7	7	1996	1996-07
8	8	1996	1996-08
9	9	1996	1996-09
10	10	1996	1996-10
11	11	1996	1996-11
12	12	1996	1996-12
13	13	1997	1997-01
14	14	1997	1997-02
15	15	1997	1997-03
16	16	1997	1997-04
17	17	1997	1997-05
18	18	1997	1997-06
19	19	1997	1997-07
20	20	1997	1997-08
21	21	1997	1997-09
22	22	1997	1997-10
23	23	1997	1997-11
24	24	1997	1997-12
25	25	1998	1998-01
26	26	1998	1998-02

3. Création de la dimension Employée

Pour construire la dimension **Employées**, j'ai d'abord réalisé une série de fusions successives dans Power Query afin de regrouper toutes les informations nécessaires provenant des différentes tables liées.


- **1. Fusion Employee + EmployeeTerritories**

J'ai commencé par effectuer une fusion entre la table **Employees** et la table **EmployeeTerritories** en utilisant la clé **EmployeeID**. Cette opération permet d'associer à chaque employé les territoires auxquels il est rattaché.



- **2. Sélection des colonnes nécessaires**



Après la fusion, j'ai cliqué sur l'icône d'expansion de la colonne issue de *EmployeeTerritories* <-> et j'ai sélectionné uniquement les attributs utiles pour la suite du traitement.



EmployeeID	LastName	FirstName	Source_Prod	EmployeesTerritories.TerritoryID
1	Davolio	Nancy	Sql Server	06897
2	Davolio	Nancy	Sql Server	19713
3	Fuller	Andrew	Sql Server	01581
4	Fuller	Andrew	Sql Server	01730
5	Fuller	Andrew	Sql Server	01833
6	Fuller	Andrew	Sql Server	02116
7	Fuller	Andrew	Sql Server	02139
8	Fuller	Andrew	Sql Server	02184
9	Fuller	Andrew	Sql Server	40222
10	Leverling	Janet	Sql Server	30346
11	Leverling	Janet	Sql Server	31406
12	Leverling	Janet	Sql Server	32859
13	Leverling	Janet	Sql Server	33607
14	Peacock	Margaret	Sql Server	20852
15	Peacock	Margaret	Sql Server	27403
16	Peacock	Margaret	Sql Server	27511
17	Buchanan	Steven	Sql Server	02903
18	Buchanan	Steven	Sql Server	07960
19	Buchanan	Steven	Sql Server	08837
20	Buchanan	Steven	Sql Server	10019
21	Buchanan	Steven	Sql Server	10038
22	Buchanan	Steven	Sql Server	11747
23	Buchanan	Steven	Sql Server	14450
24	Soyama	Michael	Sql Server	85014
25	Soyama	Michael	Sql Server	85251
26	Soyama	Michael	Sql Server	98004


• 3. Fusion avec la table Territories

Le résultat obtenu a ensuite été fusionné avec la table **Territories** en utilisant la clé **TerritoryID**. Cette étape permet de récupérer les informations détaillées sur chaque territoire.



• 4. Expansion et sélection des champs



Comme précédemment, j'ai développé la colonne issue de *Territories* et j'ai retenu uniquement les colonnes pertinentes pour la prochaine fusion.



	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24	25	26
	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24	25	26
1	1	Davolio	Nancy	Sql Server	06897	Wilton	1																			
2	1	Davolio	Nancy	Sql Server	19713	Neward	1																			
3	2	Fuller	Andrew	Sql Server	01581	Westboro	1																			
4	2	Fuller	Andrew	Sql Server	01730	Bedford	1																			
5	2	Fuller	Andrew	Sql Server	01833	Georgetow	1																			
6	2	Fuller	Andrew	Sql Server	02116	Boston	1																			
7	2	Fuller	Andrew	Sql Server	02139	Cambridge	1																			
8	2	Fuller	Andrew	Sql Server	02184	Braintree	1																			
9	2	Fuller	Andrew	Sql Server	40222	Louisville	1																			
10	3	Leverling	Janet	Sql Server	30346	Atlanta	4																			
11	3	Leverling	Janet	Sql Server	31406	Savannah	4																			
12	3	Leverling	Janet	Sql Server	32859	Orlando	4																			
13	3	Leverling	Janet	Sql Server	33607	Tampa	4																			
14	4	Peacock	Margaret	Sql Server	20852	Rockville	1																			
15	4	Peacock	Margaret	Sql Server	27403	Greensboro	1																			
16	4	Peacock	Margaret	Sql Server	27511	Cary	1																			
17	5	Buchanan	Steven	Sql Server	02903	Providence	1																			
18	5	Buchanan	Steven	Sql Server	07960	Morristown	1																			
19	5	Buchanan	Steven	Sql Server	08837	Edison	1																			
20	5	Buchanan	Steven	Sql Server	10019	New York	1																			
21	5	Buchanan	Steven	Sql Server	10038	New York	1																			
22	5	Buchanan	Steven	Sql Server	11747	Melville	1																			
23	5	Buchanan	Steven	Sql Server	14450	Fairport	1																			
24	6	Soyama	Michael	Sql Server	85014	Phoenix	2																			
25	6	Soyama	Michael	Sql Server	85251	Scottsdale	2																			
26	6	Soyama	Michael	Sql Server	85004	Glendale	2																			



- **5. Fusion avec la table Region**

La table obtenue a été fusionnée avec la table **Region** en utilisant la clé **RegionID**. Cela permet d'associer à chaque territoire la région correspondante.



- **6. Ajout des données de la source Excel**

Une fois les informations du SQL Server regroupées, j'ai ajouté la table **Employees** provenant de la source Excel. J'ai intégré cette nouvelle table en utilisant *Ajouter des requêtes* afin de combiner les données des deux sources .



À la fin de ces transformations, la table résultante représente la **dimension Employees** contenant l'ensemble des attributs provenant des sources SQL Server, EmployeeTerritories, Territories, Region et Excel. Je renomme alors cette table en **DIM_Employees**.

Requêtes [11]

Table.Combine({#"Colonnes supprimées", Employees_2})

EmployeeID	LastName	FirstName	Source_Prod	EmployeeTerritories...	Territories.Territory...	Territories.S
33	King	Robert	Sql Server	54025	Santa Monica	...
34	King	Robert	Sql Server	94025	Menlo Park	...
35	King	Robert	Sql Server	94105	San Francisco	...
36	King	Robert	Sql Server	95008	Campbell	...
37	King	Robert	Sql Server	95054	Santa Clara	...
38	King	Robert	Sql Server	95060	Santa Cruz	...
39	Callahan	Laura	Sql Server	19428	Philadelphia	...
40	Callahan	Laura	Sql Server	44122	Beachwood	...
41	Callahan	Laura	Sql Server	45839	Findlay	...
42	Callahan	Laura	Sql Server	53404	Racine	...
43	Dodsworth	Anne	Sql Server	03049	Hollis	...
44	Dodsworth	Anne	Sql Server	03801	Portsmouth	...
45	Dodsworth	Anne	Sql Server	48075	Southfield	...
46	Dodsworth	Anne	Sql Server	48084	Troy	...
47	Dodsworth	Anne	Sql Server	48304	Bloomfield Hills	...
48	Dodsworth	Anne	Sql Server	55113	Roseville	...
49	Dodsworth	Anne	Sql Server	55439	Minneapolis	...
50	Freehafer	Nancy	Excel		null	null
51	Cencini	Andrew	Excel		null	null
52	Kotas	Jan	Excel		null	null
53	Sergienko	Mariya	Excel		null	null
54	Thorpe	Steven	Excel		null	null
55	Neipper	Michael	Excel		null	null
56	Zare	Robert	Excel		null	null
57	Glussani	Laura	Excel		null	null

4. Création de la Table de fait

Pour créer la table de faits, j'ai ajouté une colonne d'identifiant séquentiel (ID_SEQ) dans chaque dimension afin de pouvoir établir les relations entre la table de faits et les différentes dimensions.

Requêtes [12]

Table.ReorderColumns("#Index ajouté",{"Index", "Cust

ID_SEQ	CompanyName
1	Alfreds Futterkiste
2	Ana Trujillo Emparedados
3	Antonio Moreno Taquería
4	Around the Horn
5	Berglunds snabbköp
6	Bon app'
7	Bottom-Dollar Markets
8	B's Beverages
9	Cactus Comidas para llevar
10	Centro comercial Moctezuma
11	Chop-suey Chinese
12	Comércio Mineiro
13	Consolidated Holdings
14	Drachenblut Delikatessen
15	Du monde entier
16	Eastern Connection
17	Ernst Handel
18	Familia Arquibaldo

Donc les dimensions sera :

12 ID_SEQ	12 CustomerID	12 CompanyName	12 City	12 Country	12 Source_Prod
1	1 ALFKI	Alfreds Futterkiste	Berlin	Germany	Sql Server
2	2 ANATR	Ana Trujillo Emparedados y helados	México D.F.	Mexico	Sql Server
3	3 ANTON	Antonio Moreno Taquería	México D.F.	Mexico	Sql Server
4	4 AROUT	Around the Horn	London	UK	Sql Server
5	5 BERGS	Berglunds snabbköp	Luleå	Sweden	Sql Server
6	6 BLAUS	Blauer See Delikatessen	Mannheim	Germany	Sql Server
7	7 BLONP	Blondesddsl père et fils	Strasbourg	France	Sql Server
8	8 BOLID	Bóldo Comidas preparadas	Madrid	Spain	Sql Server
9	9 BONAP	Bon app'	Marseille	France	Sql Server
10	10 BOTTM	Bottom-Dollar Markets	Tsawassen	Canada	Sql Server
11	11 BSBV	B's Beverages	London	UK	Sql Server
12	12 CACTU	Cactus Comidas para llevar	Buenos Aires	Argentina	Sql Server
13	13 CENTC	Centro comercial Moctezuma	México D.F.	Mexico	Sql Server
14	14 CHOPS	Chop-suey Chinese	Bern	Switzerland	Sql Server
15	15 COMMI	Comércio Mineiro	Sao Paulo	Brazil	Sql Server
16	16 CONSH	Consolidated Holdings	London	UK	Sql Server
17	17 DRACD	Drachenblut Delikatessen	Aachen	Germany	Sql Server
18	18 DUMON	Du monde entier	Nantes	France	Sql Server
19	19 EASTC	Eastern Connection	London	UK	Sql Server
20	20 ERNSH	Ernst Handel	Graz	Austria	Sql Server
21	21 FAMIA	Familia Arquibaldo	Sao Paulo	Brazil	Sql Server
22	22 FISSA	FISSA Fabrica Inter. Salchichas S.A.	Madrid	Spain	Sql Server
23	23 FOLIG	Folies gourmandes	Lille	France	Sql Server
24	24 FOLKO	Folk och få HB	Bräcke	Sweden	Sql Server
25	25 FRANK	Frankenversand	München	Germany	Sql Server

Requêtes [12]

Table.RenameColumns("#Colonnes permutees",{{"Index", "ID_SEQ"}})

12 ID_SEQ	12 EmployeeID	12 LastName	12 FirstName	12 Source_Prod	12 EmployeeTerritories.TerritoryID
1	1	Davolio	Nancy	Sql Server	06897
2	2	Davolio	Nancy	Sql Server	19713
3	3	Fuller	Andrew	Sql Server	01581
4	4	Fuller	Andrew	Sql Server	01730
5	5	Fuller	Andrew	Sql Server	01833
6	6	Fuller	Andrew	Sql Server	02116
7	7	Fuller	Andrew	Sql Server	02139
8	8	Fuller	Andrew	Sql Server	02184
9	9	Fuller	Andrew	Sql Server	40222
10	10	Leverling	Janet	Sql Server	30346
11	11	Leverling	Janet	Sql Server	31406
12	12	Leverling	Janet	Sql Server	32859
13	13	Leverling	Janet	Sql Server	33607
14	14	Peacock	Margaret	Sql Server	20852
15	15	Peacock	Margaret	Sql Server	27403
16	16	Peacock	Margaret	Sql Server	27511
17	17	Buchanan	Steven	Sql Server	02903
18	18	Buchanan	Steven	Sql Server	07960
19	19	Buchanan	Steven	Sql Server	08837
20	20	Buchanan	Steven	Sql Server	10019
21	21	Buchanan	Steven	Sql Server	10038
22	22	Buchanan	Steven	Sql Server	11747
23	23	Buchanan	Steven	Sql Server	14450
24	24	Suyama	Michael	Sql Server	85014
25	25	Suyama	Michael	Sql Server	85251

- **1. Union des tables Orders (SQL + Excel)**

J'ai commencé par combiner les tables **Orders** provenant des deux sources : la base **SQL Server** et le fichier **Excel**. Pour cela, j'ai utilisé l'option « *Ajouter des requêtes* » afin d'obtenir une table unique regroupant l'ensemble des commandes.

Ajouter

Concaténez les lignes de deux tables dans une seule table.

☒ Deux tables ☐ Au moins trois tables

Première table
Orders

Deuxième table
Orders_2

OK Annuler

- **2. Fusion avec la dimension Clients (DIM_Customers)**

Le tableau obtenu a été fusionné avec la dimension **DIM_Customers** en utilisant la clé **CustomerID**. Lors de cette fusion, j'ai sélectionné uniquement la colonne **ID_SEQ** afin de l'intégrer dans la future table de faits.

Fusionner

Sélectionnez des tables et les colonnes correspondantes pour créer une table fusionnée.

Orders

OrderID	CustomerID	EmployeeID	OrderDate	ShippedDate	ShippedDate-AnneeMois
10248	VINET	5	04/07/1996 00:00:00	16/07/1996 00:00:00	1996-07
10249	TOMSP	6	05/07/1996 00:00:00	10/07/1996 00:00:00	1996-07
10250	HANAR	4	08/07/1996 00:00:00	12/07/1996 00:00:00	1996-07
10251	VICTE	3	08/07/1996 00:00:00	15/07/1996 00:00:00	1996-07
10252	SUPRD	4	09/07/1996 00:00:00	11/07/1996 00:00:00	1996-07

DIM_Customers

ID_SEQ	CustomerID	CompanyName	City	Country	Source_Prod
1	ALFKI	Alfreds Futterkiste	Berlin	Germany	Sql Server
2	ANATR	Ana Trujillo Emparedados y helados	México D.F.	Mexico	Sql Server
3	ANTON	Antonio Moreno Taquería	México D.F.	Mexico	Sql Server
4	AROUT	Around the Horn	London	UK	Sql Server
5	BERGS	Berglunds snabbköp	Luleå	Sweden	Sql Server

Type de jointure
Externe gauche (toutes à partir de la première, correspondances approximatives)

☐ Utiliser la correspondance approximative pour effectuer la fusion

Options de correspondance approximative

☒ La sélection correspond à 830 des 830 lignes de la première table.

OK Annuler

Rechercher les colonnes à développer

☒ Développer ☐ Agréger

(Sélectionner toutes les colonnes)

- ☒ ID_SEQ
- ☐ CustomerID
- ☐ CompanyName
- ☐ City
- ☐ Country
- ☐ Source_Prod

☒ Utiliser le nom de la colonne d'origine comme préfixe

OK Annuler

- **3. Fusion avec la dimension Employés (DIM_Employees)**

Ensuite, j'ai réalisé une fusion entre la table des commandes et la dimension **DIM_Employees** en utilisant la clé **EmployeeID**. Comme précédemment, j'ai sélectionné uniquement la colonne **ID_SEQ**.

- **4. Fusion avec la dimension Temps (DIM_Date)**

Enfin, j'ai fusionné le tableau des commandes avec la dimension temporelle **DIM_Date**. La fusion a été réalisée en utilisant la colonne correspondant à la date de commande (**SHippedDate-AnneeMois**). Comme pour les autres dimensions, j'ai retenu uniquement la colonne **ID_SEQ**.

Le resulta sera donc :

Requêtes [13]

Customers
Employees
EmployeeTerritories
Orders
Region
Territories
Customers_2
Employees_2
Orders_2
DIM_Customers
DIM_Employee
DIM_Temps
TF_COMMENT

Table.ReorderColumns("#DIM_Temps développé",{"OrderID", "DIM_Customers.ID_SEQ", "DIM_Employee.ID_SEQ", "DIM_Temps.id_temps",

	Customers.ID_SEQ	DIM_Employee.ID_SEQ	DIM_Temps.id_temps	CustomerID	EmployeeID	OrderDate	ShippedDate
1	85	17		183 VINET		04/07/1996 00:00:00	16/07/19
2	85	17		184 VINET		04/07/1996 00:00:00	16/07/19
3	85	17		185 VINET		04/07/1996 00:00:00	16/07/19
4	85	17		186 VINET		04/07/1996 00:00:00	16/07/19
5	85	17		187 VINET		04/07/1996 00:00:00	16/07/19
6	85	17		188 VINET		04/07/1996 00:00:00	16/07/19
7	85	17		189 VINET		04/07/1996 00:00:00	16/07/19
8	85	17		190 VINET		04/07/1996 00:00:00	16/07/19
9	85	17		191 VINET		04/07/1996 00:00:00	16/07/19
10	85	17		192 VINET		04/07/1996 00:00:00	16/07/19
11	85	17		193 VINET		04/07/1996 00:00:00	16/07/19
12	85	17		194 VINET		04/07/1996 00:00:00	16/07/19
13	85	17		195 VINET		04/07/1996 00:00:00	16/07/19
14	85	17		196 VINET		04/07/1996 00:00:00	16/07/19
15	85	17		197 VINET		04/07/1996 00:00:00	16/07/19
16	85	17		198 VINET		04/07/1996 00:00:00	16/07/19
17	85	17		199 VINET		04/07/1996 00:00:00	16/07/19
18	85	17		200 VINET		04/07/1996 00:00:00	16/07/19
19	85	17		201 VINET		04/07/1996 00:00:00	16/07/19
20	85	17		202 VINET		04/07/1996 00:00:00	16/07/19
21	85	17		203 VINET		04/07/1996 00:00:00	16/07/19
22	85	17		204 VINET		04/07/1996 00:00:00	16/07/19
23	85	17		205 VINET		04/07/1996 00:00:00	16/07/19
24	85	17		206 VINET		04/07/1996 00:00:00	16/07/19

Paramètres d'une requête

PROPRIÉTÉS

Nom
TF_COMMENT

Toutes les propriétés

ÉTAPES APPLIQUÉES

- Source
- DIM_Customers développé
- Colonnes permutes
- Requêtes fusionnées
- DIM_Employee développé
- Colonnes permutes1
- Requêtes fusionnées1
- DIM_Temps développé
- Colonnes permutes2

Enfin j'ai ajouté deux colone pour le nombre des commandes livre et no livre :

Colonne personnalisée

Ajoutez une colonne calculée à partir des autres colonnes.

Nouveau nom de colonne
NBLIVRE

Formule de colonne personnalisée

```
= if [ShippedDate]<> null and [ShippedDate]<>"" then 1 else 0
```

Colonnes disponibles

- OrderID
- CustomerID
- EmployeeID
- OrderDate
- ShippedDate
- ORDERDATE_ANNEEMOIS
- DIM_Customers.ID_SEQ

<< Insérer

En savoir plus sur les formules Power Query

✓ Aucune erreur de syntaxe n'a été détectée.

OK Annuler

Colonne personnalisée

Ajoutez une colonne calculée à partir des autres colonnes.

Nouveau nom de colonne
NBNOLIVRE

Formule de colonne personnalisée

```
= if [ShippedDate] = null and [ShippedDate]=" " then 1 else 0
```

Colonnes disponibles

- OrderID
- CustomerID
- EmployeeID
- OrderDate
- ShippedDate
- ORDERDATE_ANNEEMOIS
- DIM_Customers.ID_SEQ

<< Insérer

En savoir plus sur les formules Power Query


✓ Aucune erreur de syntaxe n'a été détectée.

OK Annuler

Le Resulta sera donc :

	A ^c	DIM_Customers.Country	I ² ₃	DIM_Employee.ID_SEQ	I ² ₃	DIM_Temps.ID_SEQ	A ^c	DIM_Temps.annee	ABC 123	NBLIVRE	ABC 123	NBNOLIVRE
1		France		17		7	1996			1		0
2		France		18		7	1996			1		0
3		France		19		7	1996			1		0
4		France		20		7	1996			1		0
5		France		21		7	1996			1		0
6		France		22		7	1996			1		0
7		France		23		7	1996			1		0
8		France		54		7	1996			1		0
9		Switzerland		17		7	1996			1		0
10		Switzerland		18		7	1996			1		0
11		Switzerland		19		7	1996			1		0
12		Switzerland		20		7	1996			1		0
13		Switzerland		21		7	1996			1		0
14		Switzerland		22		7	1996			1		0
15		Switzerland		23		7	1996			1		0
16		Switzerland		54		7	1996			1		0
17		USA		17		7	1996			1		0
18		USA		18		7	1996			1		0
19		USA		19		7	1996			1		0
20		USA		20		7	1996			1		0
21		USA		21		7	1996			1		0
22		USA		22		7	1996			1		0
23		USA		23		7	1996			1		0
24		USA		54		7	1996			1		0
25		Austria		1		7	1996			1		0
26		Austria		2		7	1996			1		0

Ensuite, on passe à l'agrégation, en effectuant Group By, sur les ID des trois dimensions, et en calculant la somme de Shipped pour avoir le nombre de commandes livrées (NbShippedOrders) et la somme de NonShipped pour avoir le nombre de commandes non livrées (NbNonShippedOrders) :



×

Regrouper par

Spécifiez les colonnes de regroupement et une ou plusieurs sorties.

☐ De base

☒ Avancé

DIM_Customers.ID_SEQ

DIM_Employee.ID_SEQ

DIM_Temps.ID_SEQ

Ajouter un regroupement

Nouveau nom de colonne	Opération	Colonne
NN-LIVREE	Somme	livre
NB-NOLIVREE	Somme	NO_livre
Ajouter une agrégation		

OK

Annuler


Le résultat final de la table de fait sera :

	1.2 DIM_Customers.ID_SEQ	1.2 DIM_Employee.ID_SEQ	1.2 DIM_Temps.ID_SEQ	1.2 NN-LIVREE	1.2 NB-NOLIVREE
1	68	12	24	2	0
2	41	39	20	2	0
3	35	53	26	2	0
4	71	57	20	2	0
5	87	41	13	2	0
6	71	22	22	2	0
7	87	40	13	2	0
8	34	11	27	2	0
9	69	16	8	2	0
10	68	11	24	2	0
11	9	41	27	2	0
12	87	22	10	2	0
13	5	12	14	2	0
14	35	14	26	2	0
15	39	48	25	2	0
16	87	23	10	2	0
17	14	16	28	2	0
18	84	11	25	2	0
19	83	2	27	2	0
20	87	54	10	2	0
21	69	15	8	2	0
22	35	15	26	2	0
23	87	19	10	2	0
24	30	17	26	2	0
25	65	50	10	2	0
26	84	13	25	2	0

1.1.6 Modèle en étoile final

Une fois toutes les transformations terminées :

1. Cliquer sur *****Fermer et appliquer*****
2. Dans Power BI Desktop, aller dans la vue **Modèle** (icône à gauche)
3. Vérifier les relations automatiquement créées :
 - FAIT_Orders[FK_Customer] → DIM_Customers[IdSeqCustomer]
 - FAIT_Orders[FK_Employee] → DIM_Employees[IdSeqEmployee]
 - FAIT_Orders[FK_Time] → DIM_Temps[IdSeqTime]




1.2 Talend Open Studio :

Talend Open Studio est un outil ETL open-source qui permet de créer des flux de données complexes de manière visuelle. Dans cette section, nous illustrons comment les dimensions peuvent être créées avec Talend.

1.2.1 Création des demensions

1. Dim_Customers :




DESKTOP-DG...o.DCustomer

	IdSeqCustomer	CustomerID	SourceProd	CompanyName	City	Country
▶	601	ALFKI	SQLServer	Alfreds Futterkis...	Berlin	Germany
	602	ANATR	SQLServer	Ana Trujillo Em...	México D.F.	Mexico
	603	ANTON	SQLServer	Antonio Moren...	México D.F.	Mexico
	604	AROUT	SQLServer	Around the Horn	London	UK
	605	BERGS	SQLServer	Berglunds snab...	Luleå	Sweden
	606	BLAUS	SQLServer	Blauer See Deli...	Mannheim	Germany
	607	BLONP	SQLServer	Blondesddl pè...	Strasbourg	France
	608	BOLID	SQLServer	Bólido Comidas...	Madrid	Spain
	609	BONAP	SQLServer	Bon app'	Marseille	France
	610	BOTTM	SQLServer	Bottom-Dollar ...	Tsawassen	Canada
	611	BSBEV	SQLServer	B's Beverages	London	UK
	612	CACTU	SQLServer	Cactus Comidas...	Buenos Aires	Argentina
	613	CENTC	SQLServer	Centro comerci...	México D.F.	Mexico
	614	CHOPS	SQLServer	Chop-suey Chin...	Bern	Switzerland
	615	COMMI	SQLServer	Comércio Minei...	Sao Paulo	Brazil
	616	CONSH	SQLServer	Consolidated H...	London	UK
	617	DRACD	SQLServer	Drachenblut De...	Aachen	Germany
	618	DUMON	SQLServer	Du monde entier	Nantes	France
	619	EASTC	SQLServer	Eastern Connect...	London	UK
	620	ERNSH	SQLServer	Ernst Handel	Graz	Austria
	621	FAMIA	SQLServer	Familia Arquiba...	Sao Paulo	Brazil
	622	FISSA	SQLServer	FISSA Fabrica In...	Madrid	Spain
	623	FOLIG	SQLServer	Folies gourman...	Lille	France
	624	FOLKO	SQLServer	Folk och få HB	Bräcke	Sweden
	625	FRANK	SQLServer	Frankenversand	München	Germany
	626	FRANR	SQLServer	France restaurat...	Nantes	France
	627	FRANS	SQLServer	Franchi S.p.A.	Torino	Italy
	628	FURIB	SQLServer	Furia Bacalhau ...	Lisboa	Portugal
	629	GALED	SQLServer	Galería del gast...	Barcelona	Spain

1 de 120


La cellule est en lecture seule.

2. Dim_Employee :




IdSeqEmployee	EmployeeID	SourceProd	LastName	FirstName	Territory	TerritoryDescr	Region
188617	7	SQLserver	King	Robert	60601	Chicago	2
188618	7	SQLserver	King	Robert	80202	Denver	2
188619	7	SQLserver	King	Robert	80909	Colorado Sprin...	2
188620	7	SQLserver	King	Robert	90405	Santa Monica ...	2
188621	7	SQLserver	King	Robert	94025	Menlo Park	2
188622	7	SQLserver	King	Robert	94105	San Francisco ...	2
188623	7	SQLserver	King	Robert	95008	Campbell	2
188624	7	SQLserver	King	Robert	95054	Santa Clara	2
188625	7	SQLserver	King	Robert	95060	Santa Cruz	2
188626	8	SQLserver	Callahan	Laura	19428	Philadelphia	3
188627	8	SQLserver	Callahan	Laura	44122	Beachwood ...	3
188628	8	SQLserver	Callahan	Laura	45839	Findlay	3
188629	8	SQLserver	Callahan	Laura	53404	Racine	3
188630	9	SQLserver	Dodsworth	Anne	03049	Hollis	3
188631	9	SQLserver	Dodsworth	Anne	03801	Portsmouth	3
188632	9	SQLserver	Dodsworth	Anne	48075	Southfield	3
188633	9	SQLserver	Dodsworth	Anne	48084	Troy	3
188634	9	SQLserver	Dodsworth	Anne	48304	Bloomfield Hill...	3
188635	9	SQLserver	Dodsworth	Anne	55113	Roseville	3
188636	9	SQLserver	Dodsworth	Anne	55439	Minneapolis ...	3
188637	1	ACCESS	Freehafer	Nancy			0
188638	2	ACCESS	Cencini	Andrew			0
188639	3	ACCESS	Kotas	Jan			0
188640	4	ACCESS	Sergienko	Mariya			0
188641	5	ACCESS	Thorpe	Steven			0
188642	6	ACCESS	Neipper	Michael			0
188643	7	ACCESS	Zare	Robert			0
188644	8	ACCESS	Giussani	Laura			0
188645	9	ACCESS	Helluna-Larsen	Anne			0

3. Dim_Temps :



YearD	MonthYear	IdTime
1996	1996-07	1
1996	1996-08	2
1996	1996-09	3
1996	1996-10	4
1996	1996-11	5
1996	1996-12	6
1997	1997-01	7
1997	1997-02	8
1997	1997-03	9
1997	1997-04	10
1997	1997-05	11
1997	1997-06	12
1997	1997-07	13
1997	1997-08	14
1997	1997-09	15
1997	1997-10	16
1997	1997-11	17
1997	1997-12	18
1998	1998-01	19
1998	1998-02	20
1998	1998-03	21
1998	1998-04	22
1998	1998-05	23
1998	1998-06	24
1998	1998-07	25
1998	1998-08	26
1998	1998-09	27
1998	1998-10	28
1998	1998-11	29

4. Table_Fait :



1.3 Comparaison entre Power BI et Talend

Parmi les outils les plus utilisés pour créer une Data Warehouse est **Power BI** et **Talend Open Studio**. Bien qu'ils soient souvent utilisés dans un même projet décisionnel, leurs rôles sont différents et complémentaires.

1.3.1 Rôle de Power BI

Power BI est un outil de **Business Intelligence** principalement destiné à l'analyse, la modélisation et la visualisation des données. Dans ce projet, Power BI a été utilisé pour :

- L'extraction des données depuis différentes sources (SQL Server et Excel),
- Le nettoyage et la transformation des données via **Power Query**,
- La création des dimensions et de la table de faits,
- La modélisation du Data Warehouse,
- La préparation des données pour l'analyse décisionnelle.

Power BI offre une interface graphique intuitive qui facilite la manipulation des données, mais il reste limité lorsqu'il s'agit de traitements ETL complexes ou de gestion de très grands volumes de données.

1.3.2 Rôle de Talend Open Studio

Talend Open Studio est un outil spécialisé dans les processus **ETL** (Extract, Transform, Load). Il est principalement utilisé pour :

- L'extraction des données depuis plusieurs sources hétérogènes,
- Le nettoyage et la transformation avancée des données,
- L'automatisation des flux d'intégration,
- Le chargement des données dans un Data Warehouse.

Contrairement à Power BI, Talend est plus orienté vers le traitement technique des données et nécessite des compétences plus avancées, notamment en logique ETL et en manipulation des flux de données.

1.3.3 Comparaison synthétique

Critère	Power BI	Talend Open Studio
Type d'outil	Business Intelligence	ETL / Intégration de données
Objectif	Analyse et visualisation	Extraction et transformation
Nettoyage des données	Basique à intermédiaire	Avancé
Visualisation	Très développée	Absente
Facilité d'utilisation	Élevée	Moyenne à faible
Langage	DAX, Power Query (M)	Java, SQL

Power BI et Talend Open Studio ne sont pas des outils concurrents mais **complémentaires**. Talend est particulièrement adapté aux traitements ETL complexes et à l'intégration des données, tandis que Power BI est idéal pour la modélisation, l'analyse et la visualisation des données. L'utilisation conjointe de ces deux outils permet de mettre en place un Data Warehouse performant et adapté aux besoins décisionnels.

Chapitre 2

Visualisation

Dans ce chapitre, la visualisation des données a été réalisée à l'aide de trois outils et méthodes complémentaires : **Python**, **Power BI** et **Tableau**. L'objectif principal est de représenter graphiquement les résultats obtenus à partir du Data Warehouse afin de faciliter l'analyse et l'interprétation des indicateurs décisionnels.


- **Python** a été utilisé pour explorer les données, effectuer certains traitements analytiques et produire des graphiques statistiques à l'aide de bibliothèques de visualisation.
- **Power BI** a servi à créer des visualisations interactives et des tableaux de bord dynamiques, permettant d'analyser le nombre de commandes livrées et non livrées selon différentes dimensions (temps, clients, employés et pays).
- **Tableau** a été utilisé comme outil de visualisation avancée afin de comparer les résultats et d'obtenir des représentations graphiques claires et intuitives, facilitant la prise de décision.

L'utilisation combinée de ces trois outils permet d'obtenir une vision complète et complémentaire des données, en associant la flexibilité de Python, la puissance d'analyse de Power BI et la richesse visuelle de Tableau.


2.1 Power BI

2.1.1 Les commandes livrées et non livrées par années :

Dans la barre Accueil de Power Query, je clique sur Regrouper par. Une fenêtre s'ouvre et me permet de définir les paramètres du regroupement. Je remplis les champs nécessaires (colonnes de regroupement et opération), puis je valide.

A screenshot of the 'Regrouper par' (Group By) dialog box in Power Query. The dialog has a title bar 'Regrouper par' and a close button. Below the title, it says 'Spécifiez les colonnes de regroupement et une ou plusieurs sorties.' There are two radio buttons: 'De base' (selected) and 'Avancé'. Below these, there is a dropdown menu for 'Annee_Command' and a button 'Ajouter un regroupement'. Further down, there are three columns: 'Nouveau nom de colonne', 'Opération', and 'Colonne'. The first row has 'livrées' in the first column, 'Somme' in the second, and 'NBLIVRE' in the third. The second row has 'non_livrées' in the first column, 'Somme' in the second, and 'NBnoLIVRE' in the third. There is a button 'Ajouter une agrégation' below the second row. At the bottom right, there are 'OK' and 'Annuler' buttons.


Après validation, Power Query applique le regroupement et le résultat obtenu est le suivant :



Commentaire : Le nombre de commande non livrées sont nulles dans l'année 1996-1997 et très bas en 2006 et contraire a 1998.

2.1.2 Les commandes livrées et non livrées par Client :

Dans la barre Accueil de Power Query, je clique sur Regrouper par. Une fenêtre s'ouvre et me permet de définir les paramètres du regroupement. Je remplis les champs nécessaires (colonnes de regroupement et opération), puis je valide.



Regrouper par

Spécifiez les colonnes de regroupement et une ou plusieurs sorties.

☐ De base ☒ Avancé

CustomerID

Ajouter un regroupement


Nouveau nom de colonne	Opération	Colonne
Livrées	Somme	NBLIVRE
NonLivrees	Somme	NBnoLIVRE

Ajouter une agrégation

OK Annuler

Après validation, Power Query applique le regroupement et le résultat obtenu est le suivant :

CustomerID	Livrées	NonLivrees
1 VINET	35	0
2 CHOPS	47	0
3 ERNSH	164	15
4 TOMSP	34	0
5 WHITC	82	0
6 WARTH	90	0
7 RATTC	88	3
8 FOLKO	117	0
9 SPLUR	47	0
10 BLONP	63	0
11 DUMON	33	0
12 QUEDE	49	0
13 BERGS	96	0
14 BONAP	89	4
15 AROUT	62	0
16 EASTC	46	0
17 ANATR	25	0
18 BSBEV	60	0
19 HANAR	70	0
20 SUPRD	76	0
21 BOLID	16	0
22 HILAA	106	0
23 CENTC	4	0
24 OTTIK	52	0
25 DRACD	31	0
26 FRANK	66	0



Commentaire : La majorité des clients ont des commandes livrées.

2.1.3 Le nombre de commandes livrées et non livrées par employé :

Dans la barre Accueil de Power Query, je clique sur Regrouper par. Une fenêtre s'ouvre et me permet de définir les paramètres du regroupement. Je remplis les champs nécessaires

(colonnes de regroupement et opération), puis je valide.

Regrouper par

Spécifiez les colonnes de regroupement et une ou plusieurs sorties.

☐ De base ☒ Avancé

EmployeeID

Ajouter un regroupement

Nouveau nom de colonne Opération Colonne

livrées Somme NBLIVRE

non-livrées Somme NnonLIVRE

Ajouter une agrégation


OK Annuler

`= Table.Group("#Personnalisée ajoutée3", {"EmployeeID"}, {"livrées ", e`


	1.2 EmployeeID	1.2 livrées	1.2 non-livrées
1	5	336	0
2	1	375	30
3	6	414	12
4	2	760	40
5	7	781	33
6	4	636	20
7	3	665	0
8	8	510	20
9	9	416	8

Après validation, Power Query applique le regroupement et le résultat obtenu est le suivant :

Somme de livrées par EmployeeID



Somme de non-livrées par EmployeeID



Commentaire : Le nombre de commandes livrées excède le nombre de commandes non livrées par employé.

2.1.4 Les commandes livrées et non livrées par Country :

Dans la barre Accueil de Power Query, je clique sur Regrouper par. Une fenêtre s'ouvre et me permet de définir les paramètres du regroupement. Je remplis les champs nécessaires (colonnes de regroupement et opération), puis je valide.

Regrouper par

Spécifiez les colonnes de regroupement et une ou plusieurs sorties.

☐ De base ☒ Avancé

DIM_Customers.Country

Ajouter un regroupement

Nouveau nom de colonne Opération Colonne

livrée Somme NBLIVRE

nolivrée Somme NBNOLIVRE


Ajouter une agrégation

OK Annuler


= Table.Group(#"Personnalisée ajoutée3", {"DIM_Customers.Country"}, {"livre"

	DIM_Customers.Country	1.2 livre	1.2 no livre
1	France	434	15
2	Switzerland	106	5
3	Austria	236	15
4	Germany	657	16
5	USA	874	48
6	Finland	137	0
7	Sweden	213	0
8	Brazil	467	13
9	UK	318	0
10	Mexico	161	8
11	Belgium	124	0
12	Spain	135	0
13	Venezuela	239	11
14	Italy	163	4
15	Portugal	73	0
16	Ireland	125	0
17	Canada	164	6
18	Denmark	102	11
19	Poland	33	0
20	Norway	41	0
21	Argentina	91	11

Après validation, Power Query applique le regroupement et le résultat obtenu est le suivant :




2.1.5 Le dashboard final :




2.2 Tableau

2.2.1 Les commandes livrées et non livrées par années :




Commentaire : Le nombre de commande non livrées sont nulles dans l'année 1996-1997 et très bas en 2006 et contraire a 1998.

2.2.2 Les commandes livrées et non livrées par Client :




Commentaire : La majorité des clients ont des commandes livrées.

2.2.3 Le nombre de commandes livrées et non livrées par employé :




Commentaire : Le nombre de commandes livrées excède le nombre de commandes non livrées par employé.

2.2.4 Les commandes livrées et non livrées par Country :



2.2.5 Le Dashboard final :



2.3 Implémentation avec Python et Streamlit

En complément de Power BI et Talend, nous avons également développé une application web interactive utilisant **Python et Streamlit** pour visualiser les données du Data Warehouse. Cette approche offre une alternative open-source et personnalisable pour l'analyse des données.

2.3.1 Architecture de l'application


L'application a été développée avec les technologies suivantes :

- **Streamlit** : Framework Python pour créer des applications web interactives
- **Pandas** : Manipulation et analyse des données
- **Plotly** : Bibliothèque de visualisation interactive
- **OpenPyXL** : Lecture des fichiers Excel

2.3.2 Interface utilisateur

L'interface de l'application se compose de plusieurs sections :


1. Page d'accueil et importation des fichiers



L'application permet d'importer les quatre fichiers Excel via une interface intuitive dans la barre latérale :

- Fichier ANNEE
- Fichier COUNTRY
- Fichier CUSTOMER
- Fichier EMPLOYEE


2. Visualisation par Année



Le premier graphique affiche les commandes livrées et non livrées par année. On observe que :

- 1997 présente le plus grand nombre de commandes livrées (environ 2200)
- Les commandes non livrées restent faibles sur toute la période
- L'année 2006 montre une diminution significative du volume


3. Visualisation par Pays



Ce graphique à barres groupées présente la distribution des commandes par pays. Les colonnes détectées sont : DIM_Customers.Country.1, Livree, NoLivree. On constate que :

- La France domine avec environ 800 commandes livrées
- Les pays européens (Germany, UK, Switzerland) représentent une part importante
- Les commandes non livrées (en orange) restent marginales pour tous les pays

4. Visualisation par Client



La distribution par client montre que :

- La majorité des clients ont un volume de commandes livrées entre 50 et 150
- Quelques clients exceptionnels dépassent 150 commandes
- Les commandes non livrées (en orange) sont quasiment inexistantes


5. Performance des Employés



Ce graphique horizontal présente les performances de chaque employé :

- L'employé 2 affiche le volume le plus élevé (environ 800 commandes)
- Les employés 3, 4, et 7 montrent également de bonnes performances
- L'employé 5 présente le volume le plus faible
- Les barres orange (Non livré) restent très petites pour tous les employés

6. Aperçu des données brutes



The screenshot shows a Streamlit dashboard with a dark theme. At the top, there's a title 'Aperçu des données chargées' and a 'Deploy' button. Below the title, there are four data tables arranged in a 2x2 grid.

Fichier ANNEE:

	Annee	Livree	NOLivree
0	1,998	1,593	126
1	2,006	229	37
2	1,996	805	0
3	1,997	2,266	0

Fichier COUNTRY:

	DIM_Customers.Country.1	Livree	NoLivre
0	France	434	15
1	Sweden	213	0
2	Switzerland	106	5
3	Austria	236	15
4	Germany	657	16

Fichier CUSTOMER:

	CustomerID	Livree	Nolivree
0	VINET	35	0
1	CHOPS	47	0
2	TOMSP	34	0
3	HANAR	70	0
4	WELLI	56	0

Fichier EMPLOYEE:

	EmployeeID	livre	Non livre
0	1	375	30
1	2	760	40
2	7	781	33
3	8	510	20
4	9	416	8

L'application offre également un aperçu des données brutes organisées en quatre tableaux

2.3.3.Déploiement local

Pour déployer l'application en local, il faut d'abord installer les dépendances nécessaires. Dans le terminal, exécuter la commande suivante :

```
pip install streamlit pandas plotly openpyxl
```

Une fois les bibliothèques installées, l'application peut être lancée avec la commande :

```
streamlit run dashboard.py
```

Après le lancement, l'application sera accessible depuis un navigateur web à l'adresse suivante : <http://localhost:8501>

2.3.6 Justification des Choix Techniques

Dans le cadre du développement de l'application de visualisation avec Python, plusieurs bibliothèques et technologies ont été sélectionnées. Cette section justifie les choix techniques effectués en fonction des besoins du projet et des contraintes identifiées.

1.Choix de Streamlit comme Framework Web

Streamlit a été choisi comme framework principal pour le développement de l'application web interactive pour les raisons suivantes :

Avantages de Streamlit

1. **Simplicité de développement** : Streamlit permet de créer des applications web complètes en Python pur, sans nécessiter de connaissances en HTML, CSS ou JavaScript. Cela accélère considérablement le développement et permet de se concentrer sur la logique métier et la visualisation des données.
2. **Interactivité native** : Le framework offre des widgets interactifs intégrés (sliders, boutons, sélecteurs de fichiers) qui permettent de créer rapidement des interfaces utilisateur réactives. Dans notre application, l'upload des fichiers Excel se fait de manière intuitive via la barre latérale.
3. **Rechargement automatique** : Streamlit détecte automatiquement les modifications du code et recharge l'application, ce qui facilite grandement le processus de développement et de débogage.
4. **Déploiement simplifié** : L'application peut être déployée facilement en local avec une simple commande (`streamlit run`), sans configuration serveur complexe. Elle peut également être déployée gratuitement sur Streamlit Cloud pour un partage public.
5. **Documentation et communauté** : Streamlit dispose d'une documentation complète et d'une communauté active, facilitant la résolution des problèmes et l'apprentissage de bonnes pratiques.

Alternatives considérées

- **Flask/Django** : Ces frameworks nécessitent plus de code et des compétences en développement web front-end (HTML/CSS/JavaScript), ce qui aurait rallongé le temps de développement.
- **Dash (Plotly)** : Bien que puissant, Dash est plus verbeux et complexe que Streamlit pour des applications simples comme la nôtre.
- **Jupyter Notebooks** : Bien adapté pour l'exploration de données, mais ne permet pas de créer facilement des applications web déployables.

Conclusion : Streamlit offre le meilleur équilibre entre simplicité, rapidité de développement et fonctionnalités pour notre cas d'usage.

2.Choix de Pandas pour la Manipulation des Données

Pandas est la bibliothèque standard de facto pour la manipulation et l'analyse de données en Python.

Justification du choix

1. **DataFrames puissants** : Pandas fournit une structure de données DataFrame similaire aux tables SQL ou aux feuilles Excel, facilitant les opérations de filtrage, regroupement et agrégation.
2. **Compatibilité** : Pandas s'intègre parfaitement avec les autres bibliothèques de l'écosystème Python (NumPy, Plotly, Matplotlib) et permet de lire directement les fichiers Excel via OpenPyXL.
3. **Performance** : Optimisé avec NumPy et Cython, Pandas offre d'excellentes performances pour les opérations vectorisées sur des volumes de données moyens (comme ceux de Northwind).
4. **Fonctionnalités complètes** : La bibliothèque propose des fonctions avancées pour :
 - Le nettoyage des données (gestion des valeurs manquantes, doublons)
 - Les jointures et fusions de tables
 - Les opérations de groupement et d'agrégation
 - Les calculs statistiques

Exemple d'utilisation dans le projet

```
python
# Agrégation des commandes par année
df_annee = df.groupby('Annee').agg({
    'NbShippedOrders': 'sum',
    'NbNonShippedOrders': 'sum'
}).reset_index()
```

Conclusion : Pandas est le choix évident pour toute manipulation de données tabulaires en Python, offrant puissance, flexibilité et facilité d'utilisation.

3.Choix de Plotly pour les Visualisations

Plotly a été sélectionné comme bibliothèque de visualisation principale, préférée à d'autres alternatives comme Matplotlib ou Seaborn.

Avantages de Plotly

1. **Visualisations interactives** : Contrairement à Matplotlib qui génère des graphiques statiques, Plotly crée des visualisations interactives permettant :
 - Le survol pour afficher les valeurs exactes (tooltips)
 - Le zoom et le pan pour explorer les données
 - La sélection et le filtrage dynamique
 - L'export des graphiques en format PNG/SVG
2. **Esthétique moderne** : Les graphiques Plotly ont un design professionnel et moderne qui correspond aux standards actuels des dashboards BI.
3. **Intégration native avec Streamlit** : Streamlit offre un support natif de Plotly via `st.plotly_chart()`, rendant l'intégration transparente.
4. **Variété de graphiques** : Plotly propose une large gamme de types de visualisations :
 - Graphiques à barres groupées (utilisés pour les comparaisons par année, pays, client)
 - Graphiques à barres horizontales (utilisés pour les employés)
 - Graphiques en ligne, scatter plots, heatmaps, etc.

5. **Cohérence avec Power BI et Tableau** : Les visualisations Plotly offrent un niveau d'interactivité comparable à Power BI et Tableau, permettant une expérience utilisateur cohérente.

Exemple de création de graphique

```
import plotly.express as px

# Graphique à barres groupées
fig = px.bar(
    df_annee,
    x='Annee',
    y=['NbShippedOrders', 'NbNonShippedOrders'],
    title='Commandes Livrées vs Non Livrées par Année',
    labels={'value': 'Nombre de commandes', 'variable': 'Statut'},
    barmode='group',
    color_discrete_map={
        'NbShippedOrders': '#1f77b4',
        'NbNonShippedOrders': '#ff7f0e'
    }
)

fig.update_layout(
    xaxis_title='Année',
    yaxis_title='Nombre de commandes',
    legend_title='Statut de livraison'
)

st.plotly_chart(fig, use_container_width=True)
```

Alternatives considérées

- **Matplotlib** : Bibliothèque mature mais génère des graphiques statiques sans interactivité native. Nécessite plus de code pour obtenir des résultats esthétiques.
- **Seaborn** : Extension de Matplotlib offrant de meilleurs graphiques statistiques, mais toujours statiques.
- **Altair** : Excellente bibliothèque déclarative, mais moins répandue et avec une documentation moins fournie que Plotly.

Conclusion : Plotly offre le meilleur compromis entre interactivité, esthétique et facilité d'utilisation pour créer des dashboards modernes.

4.Choix de OpenPyXL pour la Lecture des Fichiers Excel

OpenPyXL est utilisé en arrière-plan par Pandas pour lire et écrire des fichiers Excel au format .xlsx.

Justification du choix

1. **Support complet d'Excel** : OpenPyXL supporte toutes les fonctionnalités modernes d'Excel (formules, styles, graphiques), contrairement à des alternatives plus anciennes comme xlrd.
2. **Format .xlsx** : Les fichiers du projet sont au format .xlsx (Excel 2007+), qui est le standard actuel. OpenPyXL est spécialement conçu pour ce format.
3. **Intégration avec Pandas** : L'installation d'OpenPyXL permet à Pandas de lire directement les fichiers Excel via `pd.read_excel()`, sans code supplémentaire.
4. **Maintenance active** : OpenPyXL est activement maintenu et compatible avec les dernières versions de Python.

Exemple d'utilisation

```
import pandas as pd

# Pandas utilise automatiquement OpenPyXL pour lire les fichiers .xlsx
df = pd.read_excel('data/Customers.xlsx', sheet_name='Sheet1')
```

Alternatives considérées

- **xlrd** : Ancienne bibliothèque qui ne supporte plus les fichiers .xlsx depuis 2020.
- **openpyxl** vs **xlsxwriter** : xlsxwriter est optimisé pour l'écriture, tandis qu'OpenPyXL est meilleur pour la lecture/écriture combinée.

5.Architecture Globale de l'Application

L'architecture de l'application Python suit une structure modulaire et organisée :

```
application/
├── dashboard.py           # Point d'entrée principal
├── requirements.txt       # Dépendances Python
└── data/                  # Dossier des données
    ├── ANNEE.xlsx
    ├── COUNTRY.xlsx
    ├── CUSTOMER.xlsx
    └── EMPLOYEE.xlsx
```

Gestion du cache avec Streamlit

```
python

@st.cache_data
def load_data(file):
    """Charge les données avec mise en cache pour optimiser les performance
    return pd.read_excel(file)
```

La décoration `@st.cache_data` permet de mettre en cache les données chargées, évitant de relire les fichiers Excel à chaque interaction utilisateur. Cela améliore considérablement les performances de l'application.

6. Avantages de l'Approche Python par Rapport aux Outils BI Classiques

Flexibilité et Personnalisation

- **Code source accessible** : Contrairement à Power BI ou Tableau, le code Python est entièrement personnalisable et versionnable (Git).
- **Automatisation complète** : Possibilité d'automatiser l'ensemble du pipeline de données via des scripts Python.
- **Intégration avec d'autres systèmes** : Python facilite l'intégration avec des API, bases de données, et services cloud.

Coût et Open Source

- **Gratuit** : Toutes les bibliothèques utilisées sont open source et gratuites, contrairement aux licences Power BI Pro ou Tableau.
- **Communauté** : Accès à une vaste communauté de développeurs et de data scientists partageant solutions et bonnes pratiques.

Portabilité

- **Multi-plateforme** : L'application fonctionne sur Windows, macOS et Linux.
- **Déploiement flexible** : Peut être déployée localement, sur un serveur, ou dans le cloud (AWS, Azure, Streamlit Cloud).

Les choix techniques effectués pour l'application Python (Streamlit, Pandas, Plotly, OpenPyXL) répondent aux objectifs du projet en offrant :

- Une **alternative open source** aux outils BI propriétaires
- Une **flexibilité maximale** pour personnaliser les analyses
- Une **expérience utilisateur moderne** avec des visualisations interactives
- Une **facilité de déploiement** et de maintenance

Cette approche complète efficacement les solutions Power BI et Tableau, démontrant la maîtrise de différentes technologies dans l'écosystème de la Business Intelligence moderne.

Conclusion

Au terme de ce projet, nous avons réussi à concevoir et à mettre en place un **Data Warehouse fonctionnel** permettant l'analyse des commandes livrées et non livrées selon plusieurs dimensions telles que le temps, les clients, les employés et les pays. L'ensemble des étapes du processus décisionnel a été respecté, depuis l'extraction des données jusqu'à la visualisation des indicateurs clés.

L'utilisation de **Power BI** a permis de faciliter la préparation et le nettoyage des données grâce à Power Query, tout en offrant une interface intuitive pour la modélisation des données et la création de tableaux de bord interactifs. La structuration des dimensions et de la table de faits a contribué à obtenir un modèle décisionnel cohérent et adapté aux besoins d'analyse.

Par ailleurs, l'exploitation de **Talend Open Studio** a permis de mieux comprendre le rôle d'un outil ETL spécialisé dans l'intégration, la transformation et l'automatisation des flux de données. La comparaison entre Power BI et Talend Open Studio a montré que ces deux outils sont complémentaires : Talend est particulièrement adapté aux traitements ETL complexes, tandis que Power BI est orienté vers l'analyse, la modélisation et la visualisation des données.

En conclusion, ce projet a permis de renforcer nos compétences pratiques en **Business Intelligence**, en **ETL** et en **Data Warehouse**, tout en offrant une vision globale du fonctionnement d'un système décisionnel. Il constitue une base solide pour des travaux futurs portant sur l'analyse de volumes de données plus importants ou l'intégration de nouvelles sources de données dans un environnement décisionnel plus avancé.